



ESC

인과추론이 필요한 이유

- 암 치료

발표의 기반이 되는 논문 ↪

REINFORCEMENT LEARNING FOR CONTROL OF NON-MARKOVIAN CELLULAR POPULATION DYNAMICS

ABSTRACT

Many organisms and cell types, from bacteria to cancer cells, exhibit a remarkable ability to adapt to fluctuating environments. Additionally, cells can leverage a memory of past environments to better survive previously-encountered stressors. From a control perspective, this adaptability poses significant challenges in driving cell populations toward extinction, and thus poses an open question with great clinical significance. In this work, we focus on drug dosing in cell populations exhibiting phenotypic plasticity. For specific dynamical models switching between resistant and susceptible states, exact solutions are known. However, when the underlying system parameters are unknown, and for complex memory-based systems, obtaining the optimal solution is currently intractable. To address this challenge, we apply reinforcement learning (RL) to identify informed dosing strategies to control cell populations evolving under novel non-Markovian dynamics. We find that model-free deep RL is able to recover exact solutions and control cell populations even in the presence of long-range temporal dynamics. To further test our approach in more realistic settings, we demonstrate robust RL-based control strategies in environments with measurement noise and dynamic memory strength.

"박테리아부터 암세포까지, 많은 유기체와 세포 유형은 변동하는 환경에 적응하는 놀라운 능력을 보인다. 또한 세포는 과거 환경의 기억을 활용해 이전에 마주쳤던 스트레스에 더 잘 생존한다."

① 문제

세포는 변동하는 환경에 적응하고 과거를 기억해 내성 획득

-> 약물 제어 어려움

② 수학적 표현

기억 효과를 가진 세포 동역학은 일반 ODE로 표현 불가

-> FDE 필요

③ 해결책

파라미터 미지 & 복잡한 기억 시스템에서 최적 투여 전략을

구하는 것은 수학적으로 불가능 -> RL의 필요성



1> 딥러닝- 상관관계의 함정

REINFORCEMENT LEARNING FOR CONTROL OF NON-MARKOVIAN CELLULAR POPULATION DYNAMICS

ABSTRACT

Many organisms and cell types, from bacteria to cancer cells, exhibit a remarkable ability to adapt to fluctuating environments. Additionally, cells can leverage a memory of past environments to better survive previously-encountered stressors. From a control perspective, this adaptability poses significant challenges in driving cell populations toward extinction, and thus poses an open question with great clinical significance. In this work, we focus on drug dosing in cell populations exhibiting phenotypic plasticity. For specific dynamical models switching between resistant and susceptible states, exact solutions are known. However, when the underlying system parameters are unknown, and for complex memory-based systems, obtaining the optimal solution is currently intractable. To address this challenge, we apply reinforcement learning (RL) to identify informed dosing strategies to control cell populations evolving under novel non-Markovian dynamics. We find that model-free deep RL is able to recover exact solutions and control cell populations even in the presence of long-range temporal dynamics. To further test our approach in more realistic settings, we demonstrate robust RL-based control strategies in environments with measurement noise and dynamic memory strength.



[사례] 폐렴 사망 위험 예측 AI

Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission

1. MOTIVATION

In the mid 90's, a large multi-institutional project was funded by Cost-Effective HealthCare (CEHC) to evaluate

the application of machine learning to important problems in healthcare such as predicting pneumonia risk. In the study, the goal was to predict the probability of death (POD) for patients with pneumonia so that high-risk patients could be admitted to the hospital while low-risk patients were treated as outpatients. In the study [3, 2], the most accurate mod-

pretable by humans. On one of the pneumonia datasets, the rule-based system learned the rule "HasAsthma(x) $\Rightarrow$ LowerRisk(x)", i.e., that patients with pneumonia who have a history of asthma have lower risk of dying from pneumonia than the general population. Needless to say, this rule is counterintuitive. But it reflected a true pattern in the training data: patients with a history of asthma who presented with pneumonia usually were admitted not only to the hospital but directly to the ICU (Intensive Care Unit). The good news is that the aggressive care received by asthmatic pneumonia patients was so effective that it lowered their risk of dying from pneumonia (compared to the general population). The bad news is that because the prognosis for these patients is better than average, models trained on the data incorrectly learn that asthma lowers risk, when in fact asthmatics have much higher risk (if not hospitalized).

→ 연구주체 및 시점 : 1990년대 피츠버그대 연구팀

→ 질환: 폐렴

→ 학습 규칙: 천식 이력이 있는 폐렴환자가 일반 인구보다 사망 위험 낮음

→ 병원에 입원 & ICU(집중치료실)로 보내짐

이러한 공격적 치료가 효과적

* 문제: 모델이 천식이 사망위험을 낮춘다고 잘못 학습

실제로 입원하지 않으면 천식 환자의 사망위험이 훨씬 높음

3. CASE STUDY: PNEUMONIA RISK

In this case study we use one of the pneumonia datasets discussed earlier in the motivation [3]. This dataset has 14,199 pneumonia patients. To facilitate comparison with

→ 데이터: 14,199명 폐렴 환자



천식 이력 있는 폐렴 환자 → AI 가 '사망 위험 낮음'으로 예측

실제 이유: 천식 환자는 즉시 ICU 입원 → 집중 치료로 실제 생존율 높음 → AI 는 'ICU 집중치료'라는 교란 변수를 보지 못하고, '천식 = 낮은 위험'이라는 상관관계를 인과관계로 착각

Confounding

투약·치료 결정이 환자 상태에 의존

천식 환자 -> 집중 치료

AI -> 치료 강도의 차이를 질병 특성으로 오인

Reverse Casuation

Y(사망률 낮음)가 X(천식 진단)를 유발하는 혼동

Selection Bias

ICU에 입원한 환자 데이터만 학습

천식이 낮은 위험이라는 편향된 패턴만 학습



[본론] 암 치료 AI- 독립적인 시나리오에서 바라본 AI가 학습한 패턴

Confounding
교란변수

내성 약한 환자에게만 공격적 투약
→ AI가 잘못 학습

피츠버그 폐경 사례

친식 있는 환자

ICV 집중치료

생존율 높음

친식 = 낮은 위험

암 치료 사례

내성 약한 환자

공격적 투약

내성 지표 ↑

강한 투약 = 내성 유발

잘못된 학습

[공통구절]

특정환자군 선별 → 의사의 적극적 개입 → 결과발생
↑
AI는 이 선별 과정을 못함



Reverse Casuation

역인과

<약이 있을 때>

감수성 세포(S) → 약에 죽음 🤪

내성 세포(R) → 약에 안 죽고 살아남 😈

<약을 끊으면>

내성 세포(R) → 살아남긴 하지만...

감수성 세포(S) → 다시 증식 시작

내성이 줄어 약을 끊은 건지,

끊어서 줄었는지 불명확

AI가 데이터에서 본 패턴: 약을 끊음 + 내성 줄어듦(상관관계, 같이 일어남)

AI가 학습한 것: 약을 끊음 → 내성 줄어듦

해석 1: 약을 끊었더니 → 내성이 줄었다 (약이 원인)

해석 2: 내성이 먼저 줄었고 → 그래서 의사가 약을 끊었다 (내성이 원인)

Selection Bias

선택 편향

임상시험은 이상적인 환자에게만 적용 → 일반 환자에 적용 불가

(중증·고령·동반질환 환자)

특정 연령대 (보통 18~65세), 해당 암 외에 다른 질환 없음, 간&신장 기능 정상, 체력 상태 양호, 이전에 다른 항암제 치료 안 받은 환자

딥러닝이 상관관계를 인과관계로 착각.. 🤪 🤪



2> 인과추론의 필요성

③ 이 환자에게 Bang-Bang 전략 대신 지속 투약을 했다면 내성이 어떻게 됐을까?

같은 환자에게 두 가지 전략을 동시에 적용 불가

반사실을 계산할 수 있어야 개인 치료 효과 ITE 추정 가능

② 지금 이 환자에게 투약하면 내성이 어떻게 변할까?

직접 개입의 결과를 묻는 것

강화학습의 $do(u=1)$ 투약, $do(u=0)$ 중단

① 증상이 질병에 대해 무엇을 말해주는가?


데이터에서 패턴을 찾는 것

암 치료에서도 이 단계에만 머물면 교란 변수 문제를 피할 수 없음

Imagining

Doing

Seeing



반사실(Counterfactual)과 ITE

* 사실 이 부분은 논문이 구현하지 못한 것(한계)

T_i : 실험대상 i 의 처치(효과를 알고자 하는 개입) 여부

Y_i : 실험대상 i 에 대해 관찰된 결과 변수

$$T_i = \begin{cases} 1 & \text{실험대상 } i \text{가 처치를 받은 경우} \\ 0 & \text{실험대상 } i \text{가 처치를 받지 않은 경우} \end{cases}$$

$T=1$: 약물 투여 $T=0$: 약물 중단

결과 $Y \rightarrow$ 내성 세포 비율

개별 처치 효과(ITE, Individual Treatment Effect)

$$ITE_i = Y_{1i} - Y_{0i}$$

Y_{0i} : 실험대상 i 가 처치를 받지 않았을 때의 잠재적 결과

Y_{1i} : 실험대상 i 가 처치를 받았을 때의 잠재적 결과

Y_{1i} : 이 환자에게 투약했을 때의 내성

Y_{0i} : 이 환자에게 투약 안 했을 때의 내성

* 문제: 둘 중 하나만 관찰 가능!

실제 일어난 것 $\rightarrow$ 사실(Factual)

일어나지 않은 것 $\rightarrow$ 반사실(Counterfactual)





3> 도메인 - 약물 투여와 내성의 관계가 인과인가 상관관계인가?

"We focus on drug dosing in cell populations exhibiting phenotypic plasticity."

논문: 표현형 가소성을 가진 세포 집단에서의 약물 투여 문제를 수학적으로 모델링

약물을 언제, 어떻게 투여?



감수성(Susceptible) 내성(Resistant)

이 환자에게 약을 언제, 얼마나 투여해야 내성을
최소화할 수 있을까?

약물 이름을 특정하지 않고, 감수성(S)과 내성(R) 두 상태 사이를 전환하는 세포 집단을 추상적으로 다룸



상관관계만 본다면 3가지 오류

① 데이터: 약물 투여량 ↑ → 내성 세포 ↑

“약물 투여가 내성을 유발한다” 고 학습

내성 세포가 먼저 증가 → 종양이 악화
의사가 악화를 보고 약물 더 투여
그런데 내성 세포는 약물에 반응하지 않으니 계속 증가

② 약물 투여를 중단한 이후 종양이 줄어드는 패턴이 관찰

“약을 끊으면 좋아진다”고 학습

(실제론 감수성 세포 회복 효과)

③ 기억 강도 α 가 낮은 환자-> 생존율 낮음

“ α 를 높이면 생존율이 높아진다” 고 학습

(α 는 생물학적 특성, 조작 불가)

인과추론으로 보면

① do(약물 투여) 개입 효과를 분리

교란 변수를 통제한 뒤 순수한 약물 투여 자체의 인과 효과만 추출

do()연산?

기존 데이터: 내성 세포 증가 → 의사 판단 → 약 투여

do()적용: 의사 판단 무시 → 강제로 약 투여

→ 이때 내성이 어떻게 변하는지?

② 반사실 시뮬레이션 가능

“이 환자에게 Bang-Bang 전략 대신 지속 투여를 했다면 내성이 어떻게 됐을까?”

다른 전략과 비교해서 검증 가능

③ α 를 조작 가능 변수로 조정

α 가 높은 환자에게는 더 긴 휴약 기간을 설계하는 개인화 전략



4> FDE

세포가 과거 약물 노출을 기억 -> 기억 효과를 수식으로 어떻게 표현?

ODE -> FDE

일반 미분방정식 ODE

마르코프 가정 따름

$$\frac{dx}{dt} = f(x(t), u(t))$$

- 현재 세포 상태 $x(t)$ & 약물 농도 $u(t)$ 로
다음 상태 결정 (과거 고려 X)
- 암세포 < 과거 기억
이전에 약물 노출 경험 있는 세포
→ 다음번 약물에 바르게 내성 표현형으로 전환

분수 미분방정식 FDE

$$D^\alpha x(t) = f(x(t), u(t))$$

D^α Caputo 분수 미분 연산자

현재 시점만 보는 것이 아니라 $t=0$ 부터 현재까지 전체 과거
이력을 가중 적분해서 계산

α 가 1에 가까우면 과거 이력의 영향이 거의 없어서 ODE와
같아짐, α 가 0에 가까울수록 먼 과거까지 영향을 미치는 강한
기억 효과가 생김


암세포의 에피제네틱 기억 강도가 α 로 수치화됨

* 약물에 노출된 경험이 DNA에 흔적으로 남아, 다음번 약물이 왔을 때 더 빠르게 내성을
발휘하는 것



4> FDE: 기억 효과를 수식화하면 인과 구조가 드러남

[DAG(Directed Acyclic Graph)] 방향 존재, 순환 x



1> 암세포의 에피제네틱 기억이 수식 포함됨

2> 과거 투약 이력의 인과적 기여가 드러남

과거일수록 인과적 기여도가 약해짐(가중 적분 의미)

$a(\text{기억 강도})$ 가 과거 투약 이력을 받아서 $x(t+1)$ 에 영향을 미침!



5> 강화학습 x 인과개입

2단계 Doing에 대응!

의사가 매 시점마다 환자 상태를 보고 치료 결정을 내리는 것처럼,

RL 에이전트도 매 시점마다 세포 집단 상태를 보고 약물 투여 여부를 결정

<핵심 기법의 인과적 의미>

FDE 환경의 MDP 설계 (RL이 FDE 위에서 작동하는 구조)

① State $x(t), u(t)$
과거 k 스텝 이력이 추가(Frame Stacking)

↪ "현재 상태"로 정의

$[x(t), u(t), x(t-1), u(t-1), \dots, u(t-k)]$

② Action do(u=1) 약물 투여 / do(u=0) 중단

③ Reward 암세포 순 사망률 최대화
 $E[Y(\pi)]$ 최대화

④ Transition 에이전트가 약물을 투여/중단 시
다음 세포 집단 상태는 과거 투여 이력
전체를 반영해서 계산

Frame Stacking **비마르코프 문제를 마르코프처럼 근사!!**

RL 에이전트는 적분 계산 x, 과거 k 스텝의 상태-행동 이력을 상태에 포함시켜서 FDE의 기억 효과를 근사

과거 약물 투여 $u(t-1) \dots u(t-k)$ 각각의 누적 인과 효과를 에이전트가 인식할 수 있게 됨

Bang-Bang Control

FDE의 해밀토니안이 u에 대해 선형,

선형함수는 양 끝에서 최대·최소

약물 투여량도 최대(투여) 아니면 최소(중단), 즉 on/off 이진 결정만이 최적



5> 실험 결과 RL이 인과적으로 올바른 전략을 발견했는가

신뢰성 검증

Markov $\alpha=1$

FDE가 일반 ODE로 수렴
수학적 최적해가 이미 알려져 있음
RL이 이 값에 수렴하는지 확인

학습된 투약 패턴

집중 투약-> 휴약-> 재투약 주기 패턴

적응적 치료의 원리와 일치

사람이 설계하지 않은 인과 전략을 자동으로 도출

실제 적용

Non-Markov $\alpha<1$ 실제 목표!

기억 효과가 있는 환경에서 Frame Stacking을
적용했을 때 내성 세포 증식 억제에 성공

강건성 검증

α 값이 변하거나 측정 노이즈가 있는 환경에서도
RL 정책의 성능이 유지

교란 변수에 강건-> 실제 임상 환경의 혼란
변수 대응 가능성



1단계 Seeing → 논문이 극복하려 한 것

6> 논문의 한계

2단계 Doing → 논문이 한 것, 3단계 Imagining → 논문이 못 한 것

① Simulation-to-Real 갭

FDE 환경은 가상모델, 실제 환자 데이터로 인과 효과 검증 미흡

② 적응증에 의한 교란

실제 임상에서 약물 투여 결정은 환자 상태에 따라 달라짐

③ α 추정의 인과성

교란 변수를 통제하지 않으면 추정값 자체가 왜곡

④ 반사실 검증 불가

동일 환자에게 두 가지 전략을 동시에 적용할 수 x

완전한 인과적 추론이라 볼 수 없다!



단기: 교란 통제

Propensity Score로 투약 선택 편향을 제거하고,
 α 추정 시 공변량을 보정

중기:

환자 상태 변화에 따라 투여를 동적으로 조절하는
적응적 투여 정책과 FDE를 결합한 인과 모델을 구축

장기:

임상 적용, Target Trial Emulation으로
실제 EHR 데이터를 검증



결론

* 심슨의 역설

상황: 바이러스 치료 약물 A vs B 비교

<전체 데이터만 보면> -> A가 더 좋아 보임

A 사망률: 16% (240/1500)

B 사망률: 19% (105/550)

<환자 상태를 나눠서 보면> (인과추론 관점) -> B가 더 나음

안정

심각

A 15% (210/1400)

30%(30/100)

B 10% (5/50)

20%(100/500)

안정적 환자에서도, 심각한 환자에서도 B가 더 낫다

A 투약군 -> 안정적 환자 1400명 + 심각한 환자 100명

B 투약군 -> 안정적 환자 50명 + 심각한 환자 500명

B에 심각한 환자가 몰렸기 때문에 전체 평균이 높게 나온 것 환자 상태라는 교란 변수를 무시하면 결론이 다르게 도출

딥러닝: "약물 투여량이 늘어날 때 내성도 늘어나더라" -> 패턴만 봄

인과추론: "왜 함께 늘어났는가? 내성이 먼저 생겨서 의사가 투여량을 늘린 것인가, 투여량이 늘어서 내성이 생긴 것인가?" -> 원인을 찾음

FDE는 암세포의 기억을 수식화해서 인과 구조를 드러냄

RL의 정책 학습은 곧 동적 인과 개입, 단, 편향 없는 환경 전제

THANK YOU
