
3. Conformal inference for censored outcomes

1> Coverage Guarantees

1. Ideal Case

완전 독립 중도절단

환자의 특성이 중도절단(Censoring) 시간에 영향을 미치지 않는 가장 이상적인 상황 $(T, X) \perp\!\!\!\perp C$

$$w(x) = \frac{1}{P(C \geq c_0 \mid X)} = \frac{1}{P(C \geq c_0)}$$

가중치를 $w(x) = \hat{w}(x) = 1$ 로 상수로 둘 수 있으며, 이 경우 Coverage가 항상 보장됨



2. Doubly Robust Coverage(이중 강건성)

현실에서는 환자의 특성이 중도절단에 영향을 미침

가중치 모델이나 생존 시간 예측 모델 중 하나만 정확히 예측해도 Coverage가 보장됨을 의미

Theorem 2. Let $N = |\mathcal{Z}_{tr}|$, $n = |\mathcal{Z}_{ca}|$, c_0 be any threshold independent of $\mathcal{Z}_{ca}$, and $q_\alpha(x; c_0)$ denote the α th conditional quantile of $T \wedge c_0$ given $X = x$. Further, let $\hat{c}(x)$ and $\hat{q}_\alpha(x; c_0)$ be estimates of $c(x)$ and $q_\alpha(x; c_0)$ respectively using $\mathcal{Z}_{tr}$, and $\hat{L}(x)$ be the corresponding CQR-LPB. Assume that there exists $\delta > 0$ such that $\mathbb{E}[1/\hat{c}(X)^{1+\delta}] < \infty$ and $\mathbb{E}[1/c(X)^{1+\delta}] < \infty$. Suppose that either A1 or A2 (or both) holds:

N, n : training set과 calibration set의 크기($N = |\mathcal{Z}_{tr}|$, $n = |\mathcal{Z}_{ca}|$)

$c(x), \hat{c}(x)$: 가중치의 역수와 이를 추정한 값

$q_\alpha(x; c_0), \hat{q}_\alpha(x; c_0)$: $X = x$ 가 주어졌을 때, $T \wedge c_0$ 의 α 분위수 정답과 이를 추정한 값

(A1) Correctly specified weight model

$$\lim_{N \rightarrow \infty} E \left[\left| \frac{1}{\hat{c}(X)} - \frac{1}{c(X)} \right| \right] = 0 \quad \text{가중치를 잘 추정한 경우}$$

(A2) Correctly specified score model

(i) For any x and $\varepsilon \in [0, r]$, if $q_\alpha(x; c_0) + \varepsilon < c_0$, then $\exists b_2 > b_1 > 0, r > 0$ s.t.

$$P(T \wedge c_0 \geq q_\alpha(x; c_0) + \varepsilon \mid X = x) \in [1 - \alpha - b_2\varepsilon, 1 - \alpha - b_1\varepsilon]$$

Score 모델을 잘 예측한 경우

(ii)

$$\lim_{N \rightarrow \infty} E \left[\frac{\mathcal{E}(X)}{\hat{c}(X)} \right] = \lim_{N \rightarrow \infty} E \left[\frac{\mathcal{E}(X)}{c(X)} \right] = 0 \quad \text{where } \mathcal{E}(x) = |\hat{q}_\alpha(x; c_0) - q_\alpha(x; c_0)|$$

Score 예측 오차: $\mathcal{E}(x) = |\hat{q}_\alpha(x; c_0) - q_\alpha(x; c_0)|$



(A1)과 (A2) 중 하나만 성립해도 근사적으로 Marginal Coverage가 보장됨

$$\lim_{N, n \rightarrow \infty} \mathbb{P}(T \wedge c_0 \geq \hat{L}(X)) \geq 1 - \alpha.$$

가정: $\hat{q}_\alpha(x; c_0) \approx q_\alpha(x; c_0)$, Conformity Score V_i 는 오라클 잔차에 가까워짐

$$V_i \approx q_\alpha(X_i; c_0) - T_i \wedge c_0$$

$\eta(x)$: V_i 의 $(1 - \alpha)$ 분위수 보정값

$$\eta(x) \approx 0$$

$$\rightarrow \hat{L}(x) = \hat{q}_\alpha(x; c_0) - \eta(x) \rightarrow \hat{L}(x) \approx \hat{q}_\alpha(x; c_0)$$



2> Adaptivity

단순히 Coverage만 넓게 보장하는 구간은 현실적 효용이 없음

모델이 우수하다면 예측 하한선 $\hat{L}(X)$ 이 얼마나 타이트하게 설정되는지가 중요!

$$\lim_{N, n \rightarrow \infty} \mathbb{P}_{X \sim Q_X}(\hat{L}(X) \geq q_\alpha(X; c_0) - \varepsilon) = 1.$$

정리: 모델이 실제 생존 시간의 분위수를 잘 추정한다면, 제안된 하한선 $\hat{L}(X)$ 은

이론적 최적값 Oracle인 $q_\alpha(X; c_0)$ 보다 아주 미세한 오차 ε 내에서 타이트하게 설정됨



3> Choice of Threshold

1. Trade-off 관계

- 임계값 c_0 는 Estimation과 Censoring 사이의 Trade-off 유발

c_0 를 크게 잡을 경우: T 와 $T \wedge c_0$ 의 차이가 줄어들어 Censoring 효과는 완화되지만, 조건을 만족하는($C \geq c_0$) 데이터 수가 감소함

c_0 를 작게 잡을 경우: 사용할 수 있는 데이터 수는 충분히 확보되지만, 예측 하한선 자체가 불필요하게 작아져 분석력이 떨어짐



2. 최적의 c_0 탐색 방법

Method 1. Finding inside the $\mathcal{Z}_{tr}$

Idea: $\mathcal{Z}_{tr}$ 을 모델 적합용(Fit)과 검증용(Holdout)으로 분할

다양한 c_0 후보군을 돌려보고, 검증용 Set에서 가장 높은 평균 하한선(LPB)을 보인 c_0 를 최종 선택

Calibration set

Method 2. Using the $\mathcal{Z}_{ca}$

데이터 크기가 제한적이어서 $\mathcal{Z}_{tr}$ 의 추가 분할이 어려울 경우 적용 가능한 대안

$$\hat{c}_0 = \operatorname{argmax}_{c_0 \in \mathcal{C}} \frac{1}{|\mathcal{I}_{ca}|} \sum_{i \in \mathcal{I}_{ca}} \hat{L}_{c_0}(X_i)$$

