
04

Estimating Epistemic Uncertainty

* Recall

동전을 100만 번 더 던져본다고 해서 이번에 던질 동전이 100% 확률로 앞면이 나온다고 확신할 수 x

Uncertainty	Def	Ex	Property
Aleatoric Uncertainty	데이터 자체에 포함된 본질적인 랜덤성 때문에 발 생하는 불확실성	동전 던지기 H/T 확률	본질적으로 제거할 수 없으며, 데 이터를 더 모아도 줄어들지 않음
Epistemic Uncertainty	모델의 지식 부족이나 학습 데이터의 한계로 인해 발생 하는 불확실성	모르는 언어의 단어 뜻 추측	추가적인 데이터나 학습을 통해 줄일 수 있음

Ex) 스와힐리어 단어 'kichwa'의 뜻 맞추기 (머리일까, 꼬리일까?)

지식 부족으로 답을 못하는 것일 뿐..

찾아보면 즉시 정답이 무엇인지 100% 확신할 수 있게 됨

참고 논문:

Aleatoric and Epistemic Uncertainty in
Machine Learning: An Introduction
to Concepts and Methods

Eyke Hüllermeier^a and Willem Waegeman^b



Bayesian ML

$$P(\theta \mid \mathcal{D}) \propto P(\theta)P(\mathcal{D} \mid \theta) = P(\theta) \prod_{i=1}^N P(x_i \mid \theta).$$

파라미터 θ 를 고정값이 아니라 확률분포로 표현
사전 분포(prior) + 데이터 → 사후 분포(posterior)

데이터 D 를 관측한 후

데이터가 늘어나면?

새로운 관측이 추가되면서
→ posterior가 점점 좁아짐
→ 가능한 θ 범위 감소
→ epistemic uncertainty 감소

Epistemic uncertainty = 파라미터 θ 에 대한 불확실성


이를 posterior distribution $P(\theta \mid D)$ 로 직접 표현

Epistemic High: 분포가 넓고 평평(High Variance) → 불확실성 큼 (지식 부족)

Epistemic Low: 분포가 특정 지점에 뾰족(Low Variance) → 불확실성 작음 (데이터 충분)



4-1 Space of Model Parameters θ



이상적인 Bayesian 학습 상황

Hypothesis space가 부족한 경우


Inductive bias가 부족한 경우




“이상적인” Bayesian 학습 상황

초기에는 불확실성이 큼 (prior가 넓음)
데이터가 쌓일수록 불확실성이 줄어들고,
올바른 모델 주변으로 확률이 집중됨

초기 상태-> 학습 과정(데이터 누적) -> 사후 분포 수렴



1 Hypothesis space가 부족한 경우




(c)

데이터를 아무리 많이 넣어도
모델이 선택할 수 있는 후보 자체가 제한되어 있기 때문에
가장 그럴듯한 '틀린 모델'로 수렴하게 됨

모델 가정이 틀리면, 데이터가 많아도 틀린 답으로 수렴!

2 Inductive bias가 부족한 경우



(d)

모델이 어디로 집중해야 할지 방향성이 부족

모델 공간은 충분히 넓은 (정답 포함)

하지만 어떤 모델이 더 좋은지 구분할 기준이 약함

→ 데이터가 있어도 posterior가
효율적으로 수축되지 않음

귀납편향

학습 시에는 만나보지 않았던
상황에 대하여 정확한 예측을
하기 위해 사용하는 추가적인
가정

+ 알파) Inductive bias(귀납 편향)



<ML 모델의 일반적인 문제점>

일반적 의미: input에 따라 모델의 결과가 달라짐

Bayesian 관점: Prior을 너무 넓고 평평하게 (Uninformative) 준다면, 모델은 현재 데이터(Likelihood)에만 의존

1. Models are brittle : 모델은 불안정하다

2. Models are spurious: 모델은 그럴싸해 보인다.

→ 일반적 의미: 데이터의 진정한 의미를 파악하는 것이 아닌 artifact, bias (결과와 편향)을 외워버리는 것

Bayesian 관점: 가설 공간안에는 진짜 정답(True Model)도 있지만, 가짜 정답(Spurious Model)들도 무수히 많음, 적절한 제약이 없다면, 제한된 데이터만으로는 이 '가짜 정답'이 데이터를 더 잘 설명하는 것처럼 보일 수 있음



성공적인 학습을 위해서는 정답을 포함할 수 있는 적절한 크기의 가설 공간과,

정답을 향해 효율적으로 수렴할 수 있게 해주는 적절한 Inductive bias가 모두 필요

$$P(\theta | \mathcal{D}) \propto P(\theta) P(\mathcal{D} | \theta) = P(\theta) \prod_{i=1}^N P(x_i | \theta),$$

posterior prior Likelihood 개별 데이터의 Likelihood

데이터를 본 후의
파라미터에 대한
확률

데이터를
보기 전의
사전 지식/초기 가정

주어진 파라미터에서
데이터가
관측될 확률

Bayesian inference는 데이터를 통해 넓은 prior hypothesis space를 점차 좁혀가며, 최종적으로 true model을 포함하는 posterior로 수렴




4-2 Approximate Posterior Distribution Families

$P(\theta \mid \mathcal{D})$: True Posterior는 intractable

→ Approximation !!

$Q_{\phi}(\theta)$: 근사 사후 분포

ϕ : 근사 분포를 결정짓는 파라미터



목표: 실제 사후 분포 P 와 가장 유사한 근사 분포 $Q_{\phi}(\theta)$ 를 찾는 최적의 파라미터 ϕ 를 결정하는 것



Dirac Delta Measure

Definition 4.16: Dirac Delta Measure

The Dirac delta is a generalized function over the real numbers whose value is zero everywhere except at zero. For our purposes, it represents the fact that we only have one possible parameter configuration θ in our posterior. Formally, it is a measure. Without going too much into Lebesgue integration theory, the gist is that it acts like a Kronecker delta.

Note: This definition only acts as an intuitive description of the Dirac measure. Interested readers should refer to measure theoretical treatments of the notion.

Deterministic ML

사후 분포에서 오직 단 하나의 파라미터 구성만을 고려하는 방식



근사 사후 분포의 선택지

$Q_{\phi}(\theta)$ can be, e.g., ...

- **...a generic multimodal distribution.** For example, it can be a Mixture of Gaussians (MoG), but any other distribution can be chosen. A MoG with an appropriate number of modes is enough to cover any continuous distributions if we allow an arbitrary number of modes.
- **...a uni-modal Gaussian distribution.** Many people like to use this for computational simplicity and tractability.
- **...a sum of Dirac delta distributions.** Some people use such semi-deterministic $Q_{\phi}(\theta)$ s.
- **...a single Dirac delta distribution.** This takes us back to deterministic ML. A deterministic posterior approximation means a single point estimate for θ (MLE, MAP).

점 추정

점 추정: 사후분포를 $\delta(\theta - \theta^*)$ 로 근사



7.1 Dirac delta function

When $f(x)$ is a well-defined function at $x = x_0$,

$$\int_{-\infty}^{\infty} \delta(x - x_0) f(x) dx = f(x_0) \int_{-\infty}^{\infty} \delta(x - x_0) dx = f(x_0).$$

The Dirac delta function $\delta(x - x_0)$ has a sharp peak at $x = x_0$.

$$\delta(x - x_0) = 0 \text{ if } x \neq x_0 \text{ and } +\infty \text{ if } x = x_0,$$

and

$$\int_{-\infty}^{\infty} \delta(x - x_0) dx = 1.$$

다른 곳은 다 0이고

→ $x = x_0$ 인 지점만 추출

사후 분포의 형태를 무엇으로 정의하느냐에 따라 모델의 성격이 결정

Dirac Delta 선택 시: 분포가 단 하나의 점으로 수렴하므로, 불확실성 0. (모든 확률 질량이 한 점에 모임)

파라미터가 고정된 값 하나만 가지게 되므로, 동일한 입력에 대해 항상 동일한 출력만 내놓는 Deterministic ML이 됨.

참고 자료:

Chapter 7
Dirac Delta function
Masatsugu Sei Suzuki
Physics Department, SUNY at Binghamton
(Date: October 6, 2010)



$$\int_{-\infty}^{\infty} \delta(x - x_0) f(x) dx = f(x_0) \int_{-\infty}^{\infty} \delta(x - x_0) dx = f(x_0).$$

Bayesian: $\downarrow$

$$p(y|x, D) = \int p(y|x, \theta) \underbrace{p(\theta|D)}_{\approx q_{\phi}(\theta)} d\theta$$

Dirac-delta
(단일 정추점) $\leftarrow \left(\begin{array}{c} \delta(\theta - \theta^*) \\ \text{가정?} \end{array} \right)$

$\Rightarrow p(y|x, \theta^*)$
 $\underline{=}$
 하나의 모델(θ^*)이
 내놓은 결과만 남음!

- 계산 효율성은 극대화됨
- 하지만 모델의 불확실성 정보는 완전히 소실됨
(overconfidence)



Quantifying Epistemic Uncertainty

BMA(Bayesian Model Averaging)

Motivation

- ① 단일 모델(Deterministic ML)의 한계 극복
: 불확실성 측정 기제의 부재
- ② 모델 집합의 다양성 활용

Goal

→ Overconfidence 방지



Deterministic vs Bayesian ML

1 Deterministic ML

$$P(y \mid x, \mathcal{D}) = P(y \mid x, \theta^*(\mathcal{D})).$$

하나의 최적 모델 θ^* 만 사용

- 모델 1개만 사용
- 빠르고 단순
- 불확실성 표현 불가능 (epistemic = 0 취급)

2 Bayesian ML

하나의 모델이 아니라

모델들의 분포 $Q_\phi(\theta \mid \mathcal{D})$ 사용

- 여러 모델을 동시에 고려
- 예측 = 여러 모델의 평균 (BMA)
- 불확실성 표현 가능



1 단일 모델(Deterministic ML)의 한계 극복

1> 구조적 취약점

데이터 부족 시, 관측된 데이터를 잘 설명할 수 있는 여러 모델 후보군 존재

하지만, ML은 하나의 최적 파라미터만 선택(실제 정답은 다른 후보 중에 있을 가능성 있음!)

미관측 영역의 불확실성을 반영 x

2> 점 추정에 따른 정보의 압축과 손실

풍부한 정보를 가진 사후분포 $P(\theta|\mathcal{D})$ 를 단일 점으로 압축: 정보 손실

가설 공간(Hypothesis Space)에 확률 분포를 부여하지 못해 모델이 가진 지식의 깊이를 보존할 수 없음

* Version Space: 현재의 데이터와 모순되지 않는 모든 가설(모델 후보)들의 집합



데이터를 똑같이 잘 설명할 수 있는 수많은 모델 후보를 계산에서 제외

단일 모델은 비교 대상이 없어 구조적으로 불확실성을 0으로 간주

EU의 근본 원인

1. The size of our training set is too small, and so the variance of our estimator is too high.
2. The training data distribution does not cover some meaningful regions in the input space; there are some underexplored areas.

- 데이터 fitting할 수 있는 모델이 수없이 많이 존재
- 관측된 데이터만으로는 어떤 모델이 True Model인지 구분 x, 예측에 대한 확신 x
- 데이터가 적기에 가설 공간 내에 수많은 후보 모델 존재 (데이터 충분->가설공간은 하나의 정답으로 좁혀짐)
- 모델 후보 많다= 여러 해석 가능= 어떤 것이 정답인지 확실히 모름



3> 사후 분포의 임의적 단일화

단일 모델을 사용하는 것: 사후 분포를 오직 한 점에만 확률이 1인 Dirac delta 분포로 정의하는 것

어떤 합리적인 Prior나 일반적인 문제 설정 하에서도 실제 사후 분포는

절대 Dirac delta 형태(점 분포)가 될 수 없음

단일 모델은 학습하지 않은 영역에 대해서도 모든 것을 안다고 착각하는 구조적 결함을 낳음

Of course, under any sensible prior belief and problem setup, the true posterior $P(\theta \mid \mathcal{D})$ will never be a sum of Dirac deltas. Nevertheless, we might use it as an *approximation* to the true posterior. In this section, we will always *approximate* the true posterior $P(\theta \mid \mathcal{D})$ w.r.t. either

ML은 가장 성장주 한 종목에 집중 투자하는 것

BMA는 여러 가능성 있는 종목에 분산 투자해 평균적인 안정 수익을 추구하는 것



2 모델 집합의 다양성 활용

1> 모델 집합의 필요성

단일 모델은 하나의 가설만 택,

BMA는 가설 공간(Version Space)에 존재하는 모든 가능성을 버리지 않고 집합으로 유지

→ 불확실성의 가시화

2> 간접적 측정

우리의 목표(직접 측정하고 싶은 것): 모델 파라미터(θ)가 얼마나 다양한지.. But 일일이 비교는 불가능

대신, y 들을 모아 평균 예측값 내기

$$P(\theta \mid \mathcal{D}) \propto P(\theta)P(\mathcal{D} \mid \theta) = P(\theta) \prod_{i=1}^N P(x_i \mid \theta),$$

우리의 관심사는 Bayesian ML임을 잊지 말 것!



Averaging

$$P(y \mid x, \mathcal{D}) = \int P(y \mid x, \theta) \underbrace{Q_\phi(\theta)}_{\approx P(\theta \mid \mathcal{D})} d\theta = \mathbb{E}_{Q_\phi(\theta)} [P(y \mid x, \theta)].$$

파라미터가 θ 로 고정된 하나의 모델이, 입력 x 에 대해 라벨 y 를 예측할 때 내는 조건부 확률
 ϕ : 분포 q_ϕ 를 결정하는 hyper-parameter
 $\Rightarrow$ 파라미터 θ 에 대한 사후분포

$\mathcal{D}$: 학습 데이터셋
 θ : 모델의 파라미터

* 이상적인 Bayesian $\Rightarrow P(\theta \mid \mathcal{D})$: posterior
 실제 계산이 어려워 Variational Inference
 (변분추론)으로 근사한 $q_\phi(\theta) \approx P(\theta \mid \mathcal{D})$ 사용

각 θ 가 가진 신뢰도 만큼 (사후 확률 Q_ϕ)만큼 $P(y \mid x, \theta)$ 에 가중치를 곱함



BMA

예측 $\rightarrow$ 하나의 모델 x , 가능한 모든 파라미터에 대해 예측을 평균 냄.

$$P(y \mid x, \mathcal{D}) = \int P(y \mid x, \theta) \underbrace{Q_{\phi}(\theta)}_{\approx P(\theta \mid \mathcal{D})} d\theta :$$

^{"모델의 예측"}
 $\nearrow$ 각 θ : 개별 모델

$\Downarrow$
 "가중치"

$\hookrightarrow$ 의미: 모든 모델을 ^(권사) posterior 확률로 가중 평균한 예측.

$$= \int P(y \mid x, \theta) \underbrace{Q_{\phi}(\theta)}_{\approx P(\theta \mid \mathcal{D})} d\theta = \mathbb{E}_{Q_{\phi}(\theta)} [P(y \mid x, \theta)] .$$

$$\theta \sim Q_{\phi}(\theta)$$



파라미터들의 평균이 아닌
 각 모델이 내놓는 예측 분포를 평균

$$P(y \mid x, \mathcal{D}) \stackrel{\text{MC}}{\approx} \frac{1}{M} \sum_{i=1}^M P(y \mid x, \theta^{(i)}), \quad \theta^{(i)} \sim Q_{\phi}(\theta).$$

$Q_{\phi}(\theta)$ 에서 샘플을 M 개 뽑아 $\nearrow$ 근사

사후분포에서 파라미터를 여러 번 샘플링한 뒤,

각 샘플 모델의 예측을 평균내는 방식

Monte Carlo 근사

: 무한히 많은 모델을 평균내는 적분을 유한한 표본 M 개로 바꾼 것



The entropy $\mathbb{H}(P(y \mid x, \mathcal{D}))$ or the max-prob for classification $\max_k P(Y = k \mid x, \mathcal{D})$ are popular choices to quantify epistemic uncertainty.

$\mathbb{H}(P(y \mid x, \mathcal{D}))$: 예측 분포의 엔트로피

$\max_k P(Y = k \mid x, \mathcal{D})$: 가장 큰 클래스 확률, 즉 max probability

- entropy가 크면 분포가 퍼져 있어서 불확실성이 큼
- max-prob가 작으면 한 클래스에 몰리지 않아서 불확실성이 큼.



+ 알파)

Predictive Uncertainty 분해

$$\text{Total} = \text{Aleatoric} + \text{Epistemic}$$

Epistemic Uncertainty

모델의 모르는 것을 측정

원인: 데이터 부족, 모델 구조 모호함

특징: 추가 데이터로 줄일 수 있음 (reducible)

측정: posterior 샘플 간 예측 분산 또는 mutual information

Bayesian Neural Network (BNN)은
신경망 가중치 ω 를 확률분포로 모델링.

BNN은 $\omega \sim p(\omega|D)$ 에서 여러
샘플을 뽑아 모델 앙상블처럼 예측.

BNN은 모델 불확실성(epistemic)을 엔트로피로 측정해 얼마나 믿을만한 예측인가 알려줌



☆☆ Overconfidence 방지

- 단일 모델 -> OOD(Out-of-Distribution) 문제 : 훈련 데이터가 없는 미탐색 영역에서 단일 모델은 잘못된 예측을 하면서도 높은 신뢰도를 보이는 경향이 있음.
- 서로 다른 예측을 내놓는 여러 모델의 결과를 평균하여 출력값을 부드럽게 만듦(Smoothing 효과)
- 모델들이 다른 예측을 할 때, 불확실성을 가시화함으로써 더 정확한 불확실성 예측을 가능케 함



Intuition of BMA

1. In-distribution (훈련 데이터 근처)

- 데이터가 충분 → 모델들이 비슷한 결정
- 모든 모델이 같은 예측
- 평균해도 확신도 매우 높음 (ex. 99%)

모델 간 일치 → 높은 신뢰도

2. Out-of-distribution (미탐색 영역)

- 데이터 부족 → 모델마다 결정이 다름
- 예측이 서로 충돌
- 평균 시 확률이 퍼짐 → 확신도 낮아짐 (ex. 40%)

모델 간 불일치 → 높은 불확실성



averaging → mixture (혼합 분포)

max 값이 smoothed (낮아짐)

argmax가 바뀔 수도 있음

모델들을 평균하면, 확률이 퍼지면서 덜 확신하게 되고,

심지어 예측 클래스도 바뀔 수 있음

Ex)

$$\text{avg}((0.51, 0.01, 0.48), (0.01, 0.51, 0.48)) = (0.26, 0.26, 0.48).$$



Ex)

$$\text{avg} \left(\underbrace{(0.51, 0.01, 0.48)}_{\text{모델 1}}, \underbrace{(0.01, 0.51, 0.48)}_{\text{모델 2}} \right) = (0.26, 0.26, 0.48).$$

$(0.51, 0.01, 0.48)$: 모델 1

$(0.01, 0.51, 0.48)$: 모델 2

n-class classification

A: class 1

B: class 2

C: class 3

A



B



C



Input이 들어온 상황



이 이미지가 각 클래스일 확률은?

같은 이미지를 보고도 모델마다 다르게 판단

<모델 1>

가나디: 51%

퀴카: 1%

잔망루피: 48%

⇒ A(가나디) 선택

<모델 2>

가나디: 1%

퀴카: 51%

잔망루피: 48%

⇒ B(퀴카) 선택

$$= (0.26, 0.26, 0.48).$$

두 모델의 "같은 클래스 확률"을 평균 낸 결과

$$(0.51, 0.01, 0.48) : \text{모델 1}$$

$$(0.01, 0.51, 0.48) : \text{모델 2}$$

$$(0.51, 0.01, 0.48) : \text{모델 1}$$

$$(0.01, 0.51, 0.48) : \text{모델 2}$$

$$\begin{array}{ccc} \text{평} & \Downarrow & \Downarrow & \Downarrow \\ \text{균} & 0.26 & 0.26 & 0.48 \\ \div 2 & & & \end{array}$$

avg

그러면 왜 avg ?

모델 1도 맞을 수 있고, 모델 2도 맞을 수 있음

두 모델의 의견을 합쳐서 하나의 확률로 만들자



4-3 Ensembling

절차

개요

여러 개의 모델을 훈련시킨 후 그 결과를 결합하여 성능을 높이는 기법

원리

손실 함수가 Non-convex하기 때문에, 시작점에 따라 서로 다른 Local Minima에 도달한다는 점을 활용

- ↪ M개의 Random seed 선택
: 매개변수 공간에서 서로 다른 시작점 설정.
1. Select M different random seeds. These are different starting points for the optimization in the parameter space.
 2. Train the M models regularly, using either a bagged dataset for each model (where we sample with replacement from the original training set) or the original training set.

↳ M개의 모델 개별 훈련
: 각 모델에 대해 bagging/ 원본 데이터셋 사용하여 독립적으로 학습 진행.

Bagging: Bootstrap + Aggregating

Bootstrap: 데이터를 무작위로 선택 -> 작은 여러 데이터로 나누기

Aggregating: 여러 모델의 결과를 결합



앙상블은 마치 집단지성!!

모델 다양성 확보 요인 (Seed의 역할)

- SGD 배치 구성: 데이터 Shuffling 순서를 변경 →
- 데이터 증강(Data Augmentation): 증강 과정의 무작위성을 부여하여 손실 지형(손실 값들을 시각화) 자체를 변화시킴
- 무작위 네트워크 구성: Dropout / DropConnect: 뉴런이나 연결을 무작위로 제거
- Stochastic Depth: 훈련 중 특정 잔차 블록(ResBlocks)을 무작위로 건너뛸

똑같은 기출문제를 풀어도 1번부터 차례대로 푸는 사람과, 역으로 푸는 사람, 무작위로 섞어서 푸는 사람은 중요하다고 느끼는 부분이 다름

매번 무작위로 사진을 비틀거나 색을 바꾸면,
난이도(손실 지형)이 변화

모델이 더 Robust한 사고방식 갖도록 함

특정 뉴런에만 의존하지 못하게 강제로 차단하여, 유연성 강화

결론: 랜덤 시드 변경과 Bagging의 결합은 앙상블 내 모델들의 다양성을 확보하여 성능을 최적화함



BMA with Ensembles

<Ensemble의 베이지안 해석> 여러 모델 M 개를 학습하면 파라미터 분포를 다음처럼 근사:

$$Q_{\phi}(\theta) = Q_{\theta^{(1)}, \dots, \theta^{(M)}}(\theta) = \frac{1}{M} \sum_{m=1}^M \delta(\theta - \theta^{(m)}).$$

각 모델 $\theta^{(m)}$ 을 Dirac delta로 표현

전체는 M 개의 모델을 평균 낸 분포

앙상블 = Bayesian Model Averaging의 근사

$$\begin{aligned} P(y | x, \mathcal{D}) &= \int P(y | x, \theta) P(\theta | \mathcal{D}) d\theta \\ &\approx \int P(y | x, \theta) Q_{\phi}(\theta) d\theta \\ &= \int P(y | x, \theta) \frac{1}{M} \sum_{m=1}^M \delta(\theta - \theta^{(m)}) d\theta \quad \text{대입} \\ &= \frac{1}{M} \sum_{m=1}^M \int P(y | x, \theta) \delta(\theta - \theta^{(m)}) d\theta \\ &= \frac{1}{M} \sum_{m=1}^M P(y | x, \theta^{(m)}). \quad \begin{array}{l} \because \int f(\theta) \delta(\theta - a) d\theta = f(a) \\ \text{Dirac-Delta 성질 이용} \end{array} \end{aligned}$$

1 Pros

- 구조가 단순함

: 모델을 M번 학습 후 평균만 하면 됨

- 범용성 높음

선형회귀부터 딥러닝까지 적용 가능

- 병렬화 가능

여러 GPU에서 동시에 학습 가능 → 속도 개선

- 성능 향상

모델 간 오류가 상쇄되어 정확도 증가

- 불확실성 표현 가능

epistemic uncertainty (모델 불확실성) 반영 가능

2 Cons

- 완전한 Bayesian은 아님

모델 수가 유한함 (이론적으로는 무한 필요), 모델 간 연결 없음 (독립적)

- 계산 비용 큼

모델 수 증가 → 비용 선형 증가

- 확장성 문제

GPU 제한 시 병렬화 어려움

학습/평가 모두 비효율적

- True posterior와 차이 있음

weight initialization에 의존한 근사

implicit prior만 반영됨 (명확하지 않음)



THANK YOU
